

**Analisis Komparatif Metode Deteksi dan Strategi Penanganan Outlier terhadap
Performa Model Klasifikasi pada Online Shoppers Purchasing Intention Dataset**

(Tugas Kelompok 1)

Mata Kuliah: IF25-3024 - Penambangan Data

Dosen Pengampu : Meida Cahyo Untoro, S.Kom., M.Kom.



Disusun oleh:

Muhammad Nurikhsan	123140057
Aryasatya Widyatna Akbar	123140164
Giovan Lado	123140068
Louis Hutabarat	123140052
Muhammad Fajri Firdaus	123140050
Martino Kelvin	123140165

Program Studi Teknik Informatika

Institut Teknologi Sumatera

2026

DAFTAR ISI

BAB I.....	3
PENDAHULUAN.....	3
1.1. Latar Belakang.....	3
1.2. Rumusan Masalah.....	3
1.3. Tujuan Penelitian.....	4
1.4. Batasan Masalah.....	4
BAB II.....	5
TINJAUAN PUSTAKA.....	5
2.1. Data Mining dan Processing.....	5
2.2. Konsep Outlier.....	5
2.3. Metode Deteksi Outlier.....	5
Tabel 1. Perbandingan Metode Deteksi Outlier.....	5
2.4. Strategi Penanganan.....	6
Tabel 2. Perbandingan Strategi Treatment Outlier.....	6
2.5. Metrik Evaluasi Klasifikasi.....	6
BAB III.....	8
METODOLOGI PENELITIAN.....	8
3.1. Alur Penelitian.....	8
Gambar 1. Alur Penelitian.....	8
3.2. Deskripsi Dataset.....	8
Tabel 3. Deskripsi Fitur Dataset Online Shoppers.....	9
3.3. Prosedur Eksperimen.....	9
3.3.1. Pembagian Data (Train-Test Split).....	9
3.3.2. Metode Deteksi dan Penanganan Outlier.....	10
3.3.3. Algoritma Klasifikasi.....	10
3.3.4. Metrik Evaluasi.....	10
BAB IV.....	12
HASIL DAN PEMBAHASAN.....	12
4.1. Eksplorasi Data (EDA).....	12
4.1.1. Gambaran Umum Dataset.....	12
Tabel 4. Statistik Deskriptif Fitur Numerik Dataset Online Shoppers.....	12
4.1.2. Distribusi Fitur Numerik.....	13
Gambar 2. Distribusi Fitur Numerik Dataset Online Shoppers.....	13
4.1.3. Distribusi Kelas Target.....	13
Gambar 3 . Distribusi Kelas Target Revenue Dataset Online Shoppers.....	13
4.2. EDA Spesifik Topik : Analisis Outlier.....	14
4.2.1. Deteksi Outlier - Boxplot Visual.....	14
Gambar 4. Boxplot Fitur Numerik.....	14
4.2.2. Deteksi Outlier 3 Metode.....	14
Tabel 5. Ringkasan Hasil Deteksi Outlier per Metode.....	14
Tabel 6. Rata-rata Fitur Numerik per Kelas Target pada Training Set.....	15
Tabel 7. mask IQR pada X_train.....	16
4.3. Implementasi Treatment Outlier.....	16
4.3.1. Pembagian Data.....	16

Tabel 8. Pembagian Data Training dan Test.....	16
4.3.2. Strategi Treatment 3 Metode.....	16
4.3.3. Visualisasi Before Vs After Treatment.....	16
Gambar 5 . Visualisasi Distribusi Before Vs After Beberapa Fitur.....	17
4.4. Hasil Perbandingan Metode.....	18
4.4.1. Pipeline Evaluasi.....	18
Tabel 9. Pipeline Evaluasi Hasil Eksperimen.....	18
4.4.2. Visualisasi Perbandingan Metrik.....	20
Gambar 6. Perbandingan Metrik Performa Pada 10 Skenario Eksperimen.....	20
Gambar 7. ROC Curve - Perbandingan 10 Skenario Eksperimen.....	20
Gambar 8. Confusion Matrix Pada 10 Skenario Eksperimen.....	21
4.5. Pembahasan.....	21
BAB V.....	23
KESIMPULAN DAN SARAN.....	23
5.1. Kesimpulan.....	23
5.2. Keterbatasan Penelitian.....	23
5.3. Saran.....	24
DAFTAR PUSTAKA.....	25
LAMPIRAN.....	26
Tabel Kontribusi Anggota Tim.....	26

BAB I

PENDAHULUAN

1.1. Latar Belakang

Dalam era *big data*, kualitas data menjadi faktor mendasar yang sangat menentukan keberhasilan proses *Knowledge Discovery in Databases* (KDD) [3]. Tahap *preprocessing*, yang mencakup pembersihan, transformasi, dan penyederhanaan informasi, diketahui menghabiskan sekitar 60–80% dari keseluruhan waktu dalam proyek *data mining*. Salah satu tantangan terbesar yang kerap ditemui pada tahap krusial ini adalah kehadiran *outlier*, yang dapat mengakibatkan penurunan kualitas generalisasi model *machine learning* secara signifikan.

Outlier atau pencilan adalah sekumpulan data yang memiliki nilai sangat berbeda dari sebagian besar data lainnya [4], serta berada jauh dari nilai rata-rata. Dalam konteks analitik *e-commerce*, seperti pada *Online Shoppers Purchasing Intention Dataset*, *outlier* sering kali muncul bukan sebagai kesalahan pengukuran (*erroneous outlier*), melainkan sebagai fenomena valid (*legitimate extreme*) [2]. Sebagai contoh, metrik durasi kunjungan halaman web (*ProductRelated_Duration*) kerap memiliki nilai ekstrim hingga puluhan ribu detik karena perilaku pengunjung yang meninggalkan *tab browser* tetap terbuka. Jika diabaikan, data yang sangat menyimpang ini bisa membuat perhitungan awal menjadi tidak akurat, menyebabkan model *overfitting*, dan merusak kemampuan sistem dalam memisahkan kelompok data.

Meskipun deteksi *outlier* banyak dibahas, penelitian terdahulu seringkali jatuh pada jebakan penanganan yang terlalu sederhana, seperti penghapusan baris data dalam jumlah besar. Pada domain *e-commerce*, menghapus pengunjung dengan durasi ekstrem berisiko tinggi menghilangkan informasi penting terkait karakteristik spesifik konsumen (*information loss*). Oleh karena itu, diperlukan evaluasi sistematis yang tidak hanya membandingkan ketajaman metode deteksi (seperti pendekatan univariat IQR dan Z-Score, maupun multivariat seperti *Isolation Forest*), tetapi juga menguji efektivitas strategi penanganan alternatif. Strategi *capping* (*winsorization*) untuk membatasi nilai ekstrim, atau *log transformation* untuk menekan *skewness* tinggi, menawarkan solusi cerdas tanpa harus membuang data.

Berdasarkan kesenjangan tersebut, penelitian ini bertujuan untuk melakukan analisis komparatif secara komprehensif antara berbagai kombinasi metode deteksi dan strategi penanganan *outlier* pada *Online Shoppers Purchasing Intention Dataset*. Melalui pengujian skenario *preprocessing* yang ketat dan bebas dari kebocoran data (*data leakage*), performa setiap strategi akan dinilai secara komprehensif menggunakan algoritma Random Forest. Pendekatan ini diharapkan dapat menjadi acuan yang kuat dalam menentukan perlakuan *outlier* yang paling optimal untuk menjaga integritas data klasifikasi pada perilaku konsumen digital.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana perbandingan efektivitas metode deteksi *outlier* (IQR, Z-Score, dan *Isolation Forest*) yang dikombinasikan dengan strategi penanganan (*Removal*, *Capping*, dan *Log Transform*) pada *Online Shoppers Purchasing Intention Dataset*?
2. Kombinasi metode manakah yang menghasilkan performa klasifikasi terbaik berdasarkan metrik komprehensif seperti *F1-Score* dan AUC-ROC?

3. Bagaimana dampak penerapan setiap strategi *preprocessing outlier* terhadap stabilitas model secara keseluruhan jika dibandingkan dengan *baseline* tanpa *preprocessing*?

1.3. Tujuan Penelitian

Tujuan dari penelitian ini secara spesifik diarahkan untuk menjawab rumusan masalah di atas, yaitu:

1. Mengimplementasikan dan membandingkan secara empiris metode deteksi IQR, Z-Score, dan *Isolation Forest* beserta strategi penanganan *Removal*, *Capping*, dan *Log Transformation* pada dataset analitik *e-commerce*.
2. Mengevaluasi performa model klasifikasi *Random Forest* untuk setiap skenario perlakuan guna mengidentifikasi kombinasi *preprocessing outlier* yang paling optimal.
3. Menganalisis dampak pembersihan atau transformasi nilai ekstrem terhadap integritas distribusi fitur dan kualitas prediktif model dibandingkan dengan *baseline*.

1.4. Batasan Masalah

1. Dataset yang digunakan adalah *Online Shoppers Purchasing Intention Dataset* yang bersumber dari repositori akademik publik (UCI Machine Learning Repository).
2. Evaluasi performa difokuskan menggunakan algoritma klasifikasi *ensemble*, yaitu *Random Forest Classifier* dengan metrik utama *F1-Score* (Macro) dan AUC-ROC untuk mengakomodasi ketidakseimbangan kelas pembeli vs non-pembeli.
3. Perbandingan dilakukan terhadap 3 metode deteksi *outlier* dan 3 strategi *treatment*, serta 1 *baseline* tanpa perlakuan.
4. Pembagian data (*train-test split*) diatur dengan rasio 80% *training* dan 20% *testing*, yang dieksekusi secara ketat sebelum proses deteksi maupun penanganan *outlier* untuk mencegah *data leakage*.

BAB II

TINJAUAN PUSTAKA

2.1. Data Mining dan Processing

Data mining merupakan proses analitik untuk mengekstraksi pola, korelasi, atau outlier dari sekumpulan data berskala besar menggunakan kombinasi metode statistik, matematis, dan komputasional. Dalam keseluruhan alur *Knowledge Discovery in Databases* (KDD), tahap *preprocessing* data merupakan fase yang sangat krusial dan memakan porsi waktu terbesar. *Preprocessing* bertujuan untuk meningkatkan kualitas data mentah sebelum dimasukkan ke dalam algoritma pembelajaran mesin, yang mencakup proses pembersihan data (*data cleaning*), integrasi, transformasi, dan reduksi [3]. Kualitas data pada tahap ini berbanding lurus dengan kualitas model yang dihasilkan.

2.2. Konsep Outlier

Outlier adalah observasi yang secara substansial berbeda dari mayoritas data dan terletak jauh dari pusat distribusi keseluruhan. Dalam analitik data *e-commerce*, *outlier* dapat berwujud kesalahan sistem (*erroneous outlier*), maupun fenomena langka yang secara behavioral nyata terjadi di populasi (*legitimate extreme*). Keberadaan *outlier* yang ekstrem, seperti durasi kunjungan *website* yang mencapai puluhan ribu detik, dapat mendistorsi rata-rata (*mean*) dan standar deviasi, mengubah koefisien regresi, dan menyebabkan model mengalami *overfitting*.

2.3. Metode Deteksi Outlier

Pendekatan untuk mendeteksi keberadaan *outlier* bervariasi dari metode statistik univariat hingga algoritma *machine learning* multivariat [4]. Penelitian ini menggunakan tiga pendekatan komparatif yang dirangkum pada Tabel 1.

Tabel 1. Perbandingan Metode Deteksi Outlier

Metode	Tipe	Prinsip Kerja	Asumsi	Threshold
IQR (Interquartile Range)	Statistik univariat	Outlier = nilai di luar $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$	Tidak mengasumsikan distribusi tertentu	$1,5 \times IQR$ (moderate)
Z-Score	Statistik univariat	Outlier = nilai dengan $\ z\ > \text{threshold}$ (umum: 3)	Mengasumsikan distribusi normal, tidak cocok untuk data <i>skewed</i>	$\ z\ > 3$ (strict)
Isolation Forest	Machine learning multivariat	Mengidentifikasi outlier berdasarkan kemudahan isolasi melalui <i>random tree splits</i>	Cocok untuk data multi-dimensi, tidak perlu asumsi distribusi	Parameter contamination

Metode IQR mendefinisikan *outlier* menggunakan batas pagar kuartil, sehingga sangat *robust* (tangguh) untuk data yang tidak berdistribusi normal. Sebaliknya, Z-Score mengukur jarak dari rata-rata, yang membuatnya kurang sensitif jika fitur memiliki *skewness* tinggi karena rata-ratanya sudah terdistorsi oleh *outlier* itu sendiri. Di sisi lain, *Isolation Forest* [2] menawarkan pendekatan multivariat dengan mengisolasi outlier pada struktur partisi pohon.

2.4. Strategi Penanganan

Setelah terdeteksi, *outlier* memerlukan penanganan agar tidak merusak model tanpa membuang informasi berharga. Terdapat tiga strategi utama yang dievaluasi dalam penelitian ini, sebagaimana dirangkum pada Tabel 2.

Tabel 2. Perbandingan Strategi Treatment Outlier

Strategi	Mekanisme	Kapan Digunakan	Risiko
Removal	Menghapus baris yang mengandung outlier	Jika yakin outlier adalah error, dataset cukup besar	Kehilangan informasi, bias jika outlier non-random
Capping / Winsorization	Membatasi nilai outlier ke batas atas/bawah ($Q1 - 1,5IQR$ atau $Q3 + 1,5IQR$)	Mempertahankan jumlah data, outlier moderate	Mengurangi variabilitas, memotong informasi distribusi ekor
Log Transformation	Menekan rentang nilai melalui transformasi $\log(1+x)$ mengurangi efek <i>skew</i> dan outlier	Data positif dan <i>right-skewed</i>	Tidak cocok untuk data negatif/nol, mengubah interpretasi fitur

Strategi *Capping* (*winsorization*) mempertahankan ukuran dataset dengan membatasi nilai *outlier* ke batas pagar IQR, berbeda dari *Removal* yang menghilangkan sampel sepenuhnya dan berisiko kehilangan informasi perilaku konsumen (*legitimate extreme*). Sementara itu, *Log Transformation* menekan lonjakan nilai yang ekstrem secara matematis, sangat ideal untuk fitur numerik yang *right-skewed* seperti durasi pengunjung *website* [5].

2.5. Metrik Evaluasi Klasifikasi

Untuk mengevaluasi efektivitas *treatment outlier* terhadap model *Random Forest*, evaluasi difokuskan pada metrik yang tahan terhadap ketidakseimbangan kelas (*imbalanced data*) [1]:

- Accuracy: Proporsi prediksi benar dari total prediksi. Kurang informatif untuk data target yang imbalanced.
- Precision: Rasio ketepatan prediksi positif ($TP/(TP+FP)$) mengukur seberapa tepat prediksi kelas pembeli.

- Recall (Sensitivity): Rasio sensitivitas ($TP/(TP+FN)$) seberapa banyak pembeli aktual yang berhasil terdeteksi.
- F1-Score: Rata-rata harmonik dari Precision dan Recall yang menjadi metrik utama pembandingan.
- AUC-ROC: Area di bawah kurva ROC yang mengukur kemampuan diskriminasi model dalam membedakan kelas pembeli dan non-pembeli.

BAB III


METODOLOGI PENELITIAN

3.1. Alur Penelitian

Penelitian ini dirancang menggunakan kerangka kerja Knowledge Discovery in Databases (KDD) yang difokuskan pada eksperimen manipulasi data di tahap preprocessing [3]. Untuk memastikan validitas hasil dan menghindari kebocoran data, serangkaian tahapan dilakukan secara berurutan. Tahap pertama diawali dengan pengumpulan data. Selanjutnya, tahap Eksplorasi Data (EDA) dilakukan untuk menganalisis karakteristik data, distribusi nilai, mengecek keberadaan missing values, serta mengidentifikasi secara visual fitur-fitur yang memiliki ketimpangan tinggi dan indikasi outlier ekstrem, seperti yang umum ditemukan pada metrik durasi halaman.

Setelah karakteristik dataset dipahami, proses dilanjutkan dengan pembagian data, di mana dataset dipisah menjadi data latih (training set) sebesar 80% dan data uji sebesar 20%. Tahapan ini dieksekusi secara ketat sebelum proses deteksi dan penanganan outlier dilakukan guna mencegah bias pada evaluasi akhir. Pada tahap implementasi, berbagai kombinasi metode deteksi outlier, yang meliputi IQR, Z-Score, dan Isolation Forest [4], diaplikasikan secara eksklusif pada data latih dan dipasangkan dengan strategi penanganan seperti Removal, Capping, serta Log Transformation [3]. Data uji sama sekali tidak menerima manipulasi agar tetap merepresentasikan kondisi data di dunia nyata. Algoritma klasifikasi Random Forest kemudian dilatih menggunakan data latih dari masing-masing skenario preprocessing, termasuk skenario baseline yang tidak diberi perlakuan outlier. Sebagai tahap akhir, performa prediktif dari setiap model dievaluasi menggunakan data uji asli, dilanjutkan dengan analisis komparatif berdasarkan metrik evaluasi klasifikasi untuk menentukan strategi penanganan outlier yang paling optimal dan menjaga integritas model.

Gambar 1. Alur Penelitian



3.2. Deskripsi Dataset

Penelitian ini menggunakan *Online Shoppers Purchasing Intention Dataset* yang bersumber dari UCI Machine Learning Repository untuk menganalisis perilaku belanja daring yang erat kaitannya dengan layanan e-commerce [2]. Dataset ini terdiri dari 12.330 sampel dengan total 18 kolom, yang mencakup 17 fitur prediktor dan satu variabel target berupa Revenue. Secara struktural, data ini tidak memiliki nilai yang hilang (*missing values*), namun menunjukkan ketidakseimbangan kelas yang cukup signifikan pada variabel targetnya; sebanyak 10.422 sampel (84,5%) termasuk dalam kategori *False* (tidak membeli), sedangkan hanya 1.908 sampel (15,5%) yang masuk dalam kategori *True* (membeli).

Tabel 3. Deskripsi Fitur Dataset Online Shoppers

No	Nama Fitur	Tipe	Deskripsi	Missing (%)
1	Administrative	Numerik	Jumlah halaman administratif yang dikunjungi	0
2	Administrative_Duration	Numerik	Total waktu (detik) di halaman administratif	0
3	Informational	Numerik	Jumlah halaman informasi yang dikunjungi	0
4	Informational_Duration	Numerik	Total waktu (detik) di halaman informasi	0
5	ProductRelated	Numerik	Jumlah halaman produk yang dikunjungi	0
6	ProductRelated_Duration	Numerik	Total waktu (detik) di halaman produk	0
7	BounceRates	Numerik	Rata-rata bounce rate halaman yang dikunjungi	0
8	ExitRates	Numerik	Rata-rata exit rate halaman yang dikunjungi	0
9	PageValues	Numerik	Rata-rata nilai halaman sebelum transaksi	0
10	SpecialDay	Numerik	Kedekatan waktu kunjungan dengan hari spesial (0–1)	0
11	Month	Kategorikal	Bulan terjadinya sesi kunjungan	0
12	OperatingSystems	Kategorikal	Sistem operasi pengunjung (encoded)	0
13	Browser	Kategorikal	Browser yang digunakan pengunjung (encoded)	0
14	Region	Kategorikal	Wilayah geografis pengunjung (encoded)	0
15	TrafficType	Kategorikal	Jenis sumber traffic pengunjung (encoded)	0
16	VisitorType	Kategorikal	Tipe pengunjung: Returning, New, Other	0
17	Weekend	Kategorikal	Apakah sesi terjadi di akhir pekan (True/False)	0
18	Revenue	Biner	Variabel target klasifikasi (True/False)	0

3.3. Prosedur Eksperimen

3.3.1. Pembagian Data (Train-Test Split)

Proses validasi model diawali dengan partisi data menjadi *training set* (80%) dan *test set* (20%). Pembagian ini diimplementasikan menggunakan teknik *stratified sampling* guna menjamin bahwa distribusi variabel target tetap representatif dan konsisten pada kedua sub-himpunan data. Secara metodologis, partisi ini dilakukan secara ketat sebelum tahapan *preprocessing* apa pun dimulai [3]. Hal ini bertujuan untuk memitigasi risiko *data leakage*, sehingga memastikan bahwa estimasi statistik dari *test set* tetap terisolasi sepenuhnya dan tidak mempengaruhi proses pelatihan model. Pendekatan ini menjamin objektivitas evaluasi terhadap performa model pada data yang belum pernah dilihat sebelumnya.

3.3.2. Metode Deteksi dan Penanganan Outlier

Desain eksperimen disusun secara menyeluruh melalui sembilan skenario kombinasi yang mengintegrasikan tiga teknik deteksi *outlier* dengan tiga strategi penanganan, ditambah satu model *baseline* sebagai kontrol komparatif. Identifikasi outlier dilakukan dengan menggabungkan pendekatan *univariat* dan *multivariat* guna memastikan integritas data yang optimal [4]. Metode *Interquartile Range (IQR)* diterapkan untuk mendeteksi outlier pada fitur yang memiliki distribusi miring (*skewed*) dengan menggunakan batas pagar $Q1 - 1,5 \times IQR$ dan $Q3 + 1,5 \times IQR$, sementara *Z-Score* digunakan sebagai detektor parametrik untuk menangkap observasi yang menyimpang lebih dari tiga standar deviasi ($||z|| > 3$) dari rata-rata [4]. Selain itu, algoritma *Isolation Forest* diimplementasikan dengan parameter (*contamination='auto'*) untuk mengidentifikasi anomali kompleks pada ruang fitur dimensi tinggi melalui mekanisme partisi pohon rekursif [2].

Terhadap data yang teridentifikasi sebagai outlier, diterapkan tiga skema mitigasi yang berbeda, *Removal* untuk mengeliminasi baris anomali secara total, *Capping (Winsorization)* guna membatasi pengaruh nilai ekstrim dengan menariknya ke ambang batas pagar tanpa mengurangi ukuran sampel, serta *Log Transformation ($\log(1+x)$)* untuk menstabilkan varians pada fitur yang memiliki kemiringan positif (*right-skewed*) [3], [5]. Untuk menjaga validitas metodologis dan mencegah bias akibat *data leakage*, seluruh parameter statistik yang digunakan dalam deteksi dan transformasi dikalkulasi secara eksklusif berdasarkan distribusi pada *training set*, yang kemudian diaplikasikan secara konsisten pada data pengujian. Pendekatan yang ketat ini menjamin bahwa model dievaluasi pada data yang benar-benar independen.

3.3.3. Algoritma Klasifikasi

Seluruh skenario *preprocessing* yang telah dideskripsikan akan dievaluasi menggunakan satu algoritma klasifikasi, yaitu *Random Forest Classifier*. Pemilihan algoritma tunggal ini bertujuan agar perbedaan performa antar-skenario dapat diatribusikan secara murni kepada perlakuan *outlier*, bukan kepada perbedaan kapasitas model. *Random Forest* bekerja dengan membangun sejumlah pohon keputusan secara paralel menggunakan teknik *bagging*, di mana prediksi akhir ditentukan melalui *majority voting* atas seluruh pohon yang dibangun. Algoritma ini dipilih karena sifatnya yang *non-parametrik*, *robust* terhadap distribusi *right-skewed*, serta mampu menangani ketidakseimbangan kelas dengan lebih baik dibandingkan model *linear* [1].

Implementasi menggunakan *RandomForestClassifier* dari pustaka *scikit-learn* dengan parameter *n_estimators = 100*, *random_state = 42* untuk memastikan reproduksibilitas, dan *class_weight = 'balanced'* untuk mengkompensasi ketidakseimbangan kelas pada variabel target *Revenue* [6]. Seluruh *hyperparameter* lainnya dibiarkan pada nilai *default* untuk menghindari bias konfigurasi antar-skenario.

3.3.4. Metrik Evaluasi

Mengingat ketidakseimbangan kelas yang signifikan pada *dataset*, di mana kelas positif (*pembeli*) hanya merepresentasikan 15,5% dari total populasi, penelitian ini menetapkan *F1-Score* sebagai metrik evaluasi utama dalam membandingkan efektivitas antar-skenario. Pemilihan ini didasarkan pada batasan inheren metrik akurasi (*accuracy*) yang cenderung memberikan interpretasi performa yang menyesatkan pada data *imbalanced* [1]. Sebagai gambaran, sebuah model naif yang hanya memprediksi kelas mayoritas secara konstan dapat mencapai

akurasi 84,5% namun sepenuhnya gagal dalam mengidentifikasi perilaku konversi pembeli.

F1-Score mengatasi bias tersebut dengan mengintegrasikan *Precision* dan *Recall* melalui rata-rata harmonik, sehingga mampu merefleksikan kapasitas sejati model dalam mendeteksi kelas minoritas secara akurat. Guna memperkuat validitas analisis, eksperimen ini juga melaporkan metrik pendukung lainnya, mencakup *Area Under the ROC Curve (AUC-ROC)* untuk mengukur kemampuan diskriminasi model pada berbagai ambang batas, serta nilai *Precision* dan *Recall* secara spesifik untuk membedah *trade-off* antara ketepatan prediksi dan cakupan deteksi pada kelas target.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Eksplorasi Data (EDA)

4.1.1. Gambaran Umum Dataset

Dataset *Online Shoppers Purchasing Intention* terdiri dari 12.330 sampel dengan 18 kolom, yang mencakup 10 fitur numerik, 7 fitur kategorikal/biner, dan satu variabel target biner *Revenue*. Berdasarkan hasil pemeriksaan awal, dataset ini tidak memiliki missing value pada seluruh kolom (0% missing), sehingga tahap imputasi tidak diperlukan dan analisis dapat langsung difokuskan pada penanganan outlier. Pemeriksaan tambahan menemukan 125 baris duplikat (1,01% dari total data). Karena dataset tidak menyediakan identifier sesi unik, dua kunjungan berbeda secara prinsip dapat menghasilkan vektor fitur agregat yang identik, terutama pada sesi singkat dengan banyak fitur bernilai nol. Pada penelitian ini, duplikat dipertahankan untuk menjaga distribusi alami data, dengan konsekuensi yang dibahas pada Bab V. Tabel 4 berikut merangkum statistik deskriptif fitur-fitur numerik utama yang menjadi fokus analisis outlier.


Tabel 4. Statistik Deskriptif Fitur Numerik Dataset *Online Shoppers*

Fitur	Mean	Std	Min	Median	Max	Skewness
Administrative	2,315	3,322	0	1,0	27	1,960
Administrative_Duration	80,819	176,779	0	7,5	3398,75	5,616
Informational	0,504	1,270	0	0,0	24	4,036
Informational_Duration	34,472	140,749	0	0,0	2549,38	7,579
ProductRelated	31,731	44,475	0	18,0	705	4,342
ProductRelated_Duration	1194,746	1913,669	0	598,94	63973,52	7,263
BounceRates	0,022	0,049	0	0,003	0,200	2,948
ExitRates	0,043	0,049	0	0,025	0,200	2,149
PageValues	5,889	18,568	0	0,0	361,76	6,383
SpecialDay	0,061	0,199	0	0,0	1,0	3,303

Berdasarkan Tabel 4, seluruh fitur numerik menunjukkan distribusi yang sangat *right-skewed* (nilai skewness > 1), dengan fitur *Informational_Duration* dan *ProductRelated_Duration* memiliki skewness tertinggi, yaitu 7,579 dan 7,263 secara berurutan. Perbedaan mencolok antara nilai mean dan median mengindikasikan kehadiran nilai ekstrem di sisi kanan distribusi. Sebagai contoh, *ProductRelated_Duration* memiliki median 598,94 detik namun maksimum

mencapai 63.973 detik, perbedaan lebih dari 100 kali lipat yang mengindikasikan keberadaan outlier ekstrim berupa sesi pengunjung yang membiarkan tab browser tetap terbuka dalam waktu sangat lama.


4.1.2. Distribusi Fitur Numerik



Gambar 2. Distribusi Fitur Numerik Dataset Online Shoppers

Gambar diatas menampilkan distribusi seluruh fitur numerik. Dapat diamati bahwa semua fitur memperlihatkan distribusi yang sangat condong ke kanan (*right-skewed*) dengan konsentrasi data yang tinggi di dekat nol dan ekor panjang ke kanan. Hal ini mengindikasikan dominannya nilai normal dengan sejumlah kecil nilai ekstrim yang sangat besar. Fitur *BounceRates* dan *ExitRates* terbatas pada rentang $[0, 0,2]$ namun tetap menunjukkan distribusi skewed karena sebagian besar halaman memiliki nilai mendekati nol. Fitur *SpecialDay* bersifat diskrit dengan nilai terbatas, mengindikasikan bahwa sebagian besar sesi kunjungan tidak berada dalam kedekatan dengan hari-hari khusus.

4.1.3. Distribusi Kelas Target




Gambar 3 . Distribusi Kelas Target Revenue Dataset Online Shoppers

Gambar diatas menunjukkan distribusi kelas target pada dataset. Kelas False memiliki 10.422 sampel (84,5%), sedangkan kelas True hanya 1.908 sampel

(15,5%), menghasilkan *imbalance ratio* (IR) sebesar 5,46. Ketidakseimbangan ini memerlukan perhatian dalam pemilihan metrik evaluasinya. *Accuracy* saja dapat menyesatkan karena model yang selalu memprediksi kelas terbanyak tanpa mendeteksi kelas lainnya. Oleh karena itu, F1-Score dan AUC-ROC ditetapkan sebagai metrik utama evaluasi, dan seluruh model menggunakan parameter *class_weight='balanced'*.

4.2. EDA Spesifik Topik : Analisis Outlier

4.2.1. Deteksi Outlier - Boxplot Visual



Gambar 4. Boxplot Fitur Numerik

Gambar diatas menampilkan boxplot nilai yang berada di luar IQR (outlier) dari fitur numerik dataset. Seluruh fitur menunjukkan nilai outlier yang banyak, khususnya fitur - fitur durasi halaman yang memiliki distribusi sangat *right-skewed*. Fitur *ProductRelated_Duration* menampilkan outlier paling ekstrim dengan nilai maksimum mencapai 63.973,52 detik (sekitar 17,8 jam), atau lebih dari 100 kali lipat nilai mediannya (598,94 detik). Hal ini menunjukkan fenomena *legitimate extreme*, dengan asumsi pengunjung yang meninggalkan tab browser dalam waktu lama dan bukan dari kesalahan pengukuran. Fitur *BounceRates* dan *ExitRates* juga memperlihatkan outlier meskipun rentang nilainya terbatas di $[0, 0,2]$, disebabkan oleh IQR yang kecil akibat distribusi yang terkonsentrasi di dekat nol.

4.2.2. Deteksi Outlier 3 Metode

Tabel 5. Ringkasan Hasil Deteksi Outlier per Metode

Metode	Outlier Terdeteksi	Persentase (%)	Sisa Data	Keterangan
IQR ($1,5 \times \text{IQR}$)	5.688	57,7%	4.176	Berbasis kuartil, tanpa asumsi distribusi
Z-Score ($ z > 3$)	1.849	18,7%	8.015	Berbasis standar deviasi, asumsi normalitas
Isolation Forest (cont=0,05)	494	5,00%	9.370	Multivariat, berbasis tree isolation

Berdasarkan tabel diatas, terdapat perbedaan dalam jumlah outlier yang terdeteksi oleh ketiga metode. Metode IQR mendeteksi jumlah outlier terbesar, yaitu 5.688 sampel (57,7%), yang secara mendominasi separuh dataset. Hal ini

disebabkan oleh distribusi yang sangat *right-skewed* pada hampir seluruh fitur, ketika IQR sangat kecil (karena median dan Q3 yang rendah), bahkan nilai sedang sekalipun dapat melampaui batas IQR. Sebagai contoh, pada fitur *Informational*, batas atas IQR bernilai 0 karena Q1 hingga Q3 bernilai 0, sehingga seluruh nilai positif (2.631 sampel, 21,34%) diklasifikasikan sebagai outlier. Hal ini menunjukkan keterbatasan IQR untuk data yang *zero-inflated*.

Metode Z-Score mendeteksi 1.849 outlier (18,7%), jauh lebih sedikit dibandingkan IQR. Perbedaan ini tidak menunjukkan keunggulan akurasi Z-Score, melainkan keterbatasannya pada distribusi non-normal. Karena threshold $|z| > 3$ didasarkan pada *mean* dan *standard deviation* yang telah terdistorsi oleh outlier itu sendiri, batas deteksi menjadi terlalu toleran dan banyak nilai ekstrem lolos dari identifikasi. Sebaliknya, Isolation Forest mengidentifikasi hanya 494 outlier (5%) sesuai dengan parameter *contamination=0,05* yang ditetapkan. Pendekatan multivariat ini mengidentifikasi outlier berdasarkan kemudahan isolasi melalui partisi pohon rekursif, sehingga lebih konservatif dan terfokus pada titik - titik yang terisolasi di ruang fitur berdimensi tinggi.

Untuk memvalidasi karakter outlier pada dataset ini, dihitung rata-rata setiap fitur numerik pada training set yang dipisahkan menurut kelas target.

Tabel 6. Rata-rata Fitur Numerik per Kelas Target pada Training Set

Fitur	Non-Pembeli	Pembeli	Rasio
Administrative	2,115	3,425	1,62×
Administrative_Duration	73,616	122,902	1,67×
Informational	0,452	0,795	1,76×
Informational_Duration	30,436	57,288	1,88×
ProductRelated	28,550	47,315	1,66×
ProductRelated_Duration	1.067,322	1.837,981	1,72×
BounceRates	0,026	0,005	0,19×
ExitRates	0,048	0,019	0,40×
PageValues	1,948	27,780	14,26×
SpecialDay	0,070	0,021	0,30×

Pembeli secara konsisten memiliki nilai fitur durasi dan jumlah halaman yang lebih tinggi, dengan PageValues mencapai rasio 14,26×. Sebaliknya, BounceRates dan ExitRates pembeli justru lebih rendah, sesuai dengan intuisi perilaku belanja. Karena metode deteksi pada distribusi *right-skewed* secara sistematis menandai nilai tinggi sebagai outlier, dan justru di sanalah pembeli berkumpul, maka penghapusan outlier secara agresif berarti menghapus sinyal kelas minoritas. Temuan ini memberikan justifikasi kuantitatif terhadap karakter *legitimate extreme* pada dataset Online Shoppers.

Tabel 7. mask IQR pada X_{train}

Kelas	Total di X_{train}	Terdeteksi Outlier IQR	Persentase (%)
Non-Pembeli	8338	4305	51.6
Pembeli	1526	1383	90.6
Total	9864	5688	57.7

4.3. Implementasi Treatment Outlier

Seluruh parameter statistik untuk deteksi dan penanganan outlier dikalkulasikan pada training set setelah proses pembagian data. Parameter tersebut kemudian diaplikasikan pada test set. Test set tidak mengalami modifikasi apapun untuk memastikan evaluasi yang objektif.

4.3.1. Pembagian Data

Tabel 8. Pembagian Data Training dan Test


Training Set	9.864 sampel
Test Set	2.466 sampel


Data dibagi menjadi training set 80 % dan test set 20% menggunakan stratified sampling untuk menjaga proporsi kelas target yang konsisten pada kedua subset. Pembagian ini dilakukan sebelum proses deteksi maupun penanganan outlier, untuk mencegah bias evaluasi akibat data leakage.

4.3.2. Strategi Treatment 3 Metode

Ketiga penanganan atau treatment diimplementasikan secara terpisah pada training set. *Removal* menghapus seluruh baris yang mengandung setidaknya satu outlier berdasarkan deteksi IQR, strategi ini mengurangi training set secara drastis. *Capping (Winsorization)* membatasi nilai outlier ke batas atau bawah IQR tanpa mengurangi jumlah sampel, mempertahankan seluruh 9.864 baris training. *Log Transformation* menerapkan transformasi log pada fitur - fitur dengan *skewness* > 0,5 untuk menekan lonjakan nilai.

4.3.3. Visualisasi Before Vs After Treatment





Gambar 5. Visualisasi Distribusi Before Vs After Beberapa Fitur

ProductRelated_Duration merupakan fitur dengan tingkat outlier paling ekstrim dalam dataset ini, yang tercermin dari nilai *skewness* asli sebesar 8,01. Penerapan metode *Removal* berhasil memangkas ekor distribusi secara signifikan hingga *skewness* turun ke angka 1,65, namun strategi ini menghilangkan banyak variasi data belanja yang sebenarnya valid. Metode *Capping* memberikan hasil yang lebih moderat dengan menekan *skewness* ke 1,16, dimana nilai-nilai ekstrem "ditarik" ke batas *upper fence* sehingga menciptakan tumpukan frekuensi di ujung kanan distribusi. Sementara itu, *Log Transformation* memberikan transformasi paling drastis dengan mengubah sebaran data menjadi jauh lebih lebar dan

mendekati bentuk lonceng (normal), meskipun arah kemiringannya sedikit bergeser menjadi negatif.

Pada fitur *Administrative_Duration*, distribusi asli menunjukkan pola yang sangat timpang dengan mayoritas data berkumpul di angka nol dan *skewness* sebesar 5,68. Penggunaan metode *Removal* menyebabkan rata-rata durasi turun secara tajam dari 81,2 menjadi 31,8 karena banyak sesi durasi panjang yang terhapus. Metode *Capping* memberikan kompromi yang lebih baik dengan menstabilkan rata-rata di angka 56,8 melalui pembatasan nilai ekstrim. Namun, *Log Transformation* tetap menjadi metode yang paling unggul karena berhasil menghasilkan distribusi yang sangat halus dengan *skewness* rendah (0,25), yang artinya data durasi kini memiliki sebaran yang lebih sehat untuk diproses oleh algoritma pembelajaran mesin.

Karakteristik unik terlihat pada fitur *Informational_Duration*, di mana metode *Removal* dan *Capping* justru memberikan hasil yang kurang ideal karena menganggap hampir seluruh nilai di atas nol sebagai outlier, sehingga distribusi akhirnya menjadi konstan dan kehilangan informasinya (mean 0,0). Fenomena ini terjadi karena frekuensi nilai nol yang terlalu dominan. Dalam kondisi ini, *Log Transformation* menjadi satu-satunya penyelamat data karena mampu mempertahankan keberadaan user yang mencari informasi produk dengan cara menyusutkan jarak matematis antar outlier, sehingga *skewness* berhasil ditekan dari 7,70 menjadi 1,92 tanpa menghapus satu pun baris data.

Fitur *PageValues* merupakan indikator krusial bagi niat beli user yang memiliki distribusi awal sangat miring (*skewness* 6,19). Sama halnya dengan durasi informasi, metode *Removal* dan *Capping* cenderung "mematikan" variasi fitur ini karena menghapus atau membatasi nilai-nilai tinggi yang sebenarnya merupakan sinyal transaksi berharga. *Log Transformation* terbukti menjadi strategi yang paling tepat karena mampu mengecilkan skala nilai tanpa menghilangkan signifikansi dari sesi yang bernilai tinggi tersebut, sehingga *skewness* akhir berada di angka 1,80. Dengan metode ini, model tetap dapat mengenali pola user yang memiliki peluang belanja besar meskipun nilai fiturnya telah dinormalisasi.

Terakhir, pada fitur *ExitRates* yang memiliki rentang nilai terbatas antara 0 hingga 1, sebaran aslinya memiliki *skewness* sebesar 2,13. Karena karakteristik fiturnya berupa rasio, metode *Removal* dan *Capping* memberikan dampak yang hampir serupa dalam merapikan ekor distribusi dan menurunkan *skewness* ke kisaran 1,12. Meskipun *Log Transformation* juga dapat digunakan, metode *Capping* terlihat lebih representatif secara visual karena berhasil membatasi halaman-halaman dengan tingkat "keluar" yang tidak wajar tanpa mengubah struktur logaritma dari persentase aslinya. Secara umum, pemilihan metode harus sangat memperhatikan apakah outlier tersebut merupakan gangguan (noise) atau justru informasi kunci seperti pada kasus durasi dan nilai halaman.

4.4. Hasil Perbandingan Metode

4.4.1. Pipeline Evaluasi

Tabel 9. Pipeline Evaluasi Hasil Eksperimen

Skenario	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Baseline (No Treatment)	0,9031	0,8462	0,7502	0,7863	0,9176
IQR+LogTransform	0,9023	0,8432	0,7498	0,7851	0,9179
IsolationForest+LogTransform	0,9023	0,8432	0,7498	0,7851	0,9179


Z-Score+LogTransform	0,9023	0,8432	0,7498	0,7851	0,9179
IsolationForest+Removal	0,8978	0,8393	0,7311	0,7695	0,9175
Z-Score+Removal	0,8982	0,8418	0,7303	0,7694	0,9162
Z-Score+Capping	0,8487	0,7183	0,5364	0,5317	0,7543
IQR+Capping	0,8487	0,7183	0,5364	0,5317	0,7543
IsolationForest+Capping	0,8487	0,7183	0,5364	0,5317	0,7543
IQR+Removal	0,8447	0,4225	0,4998	0,4579	0,6240

Sebelum interpretasi hasil, perlu diklarifikasi bahwa skenario Capping dan LogTransform menghasilkan nilai metrik yang identik di seluruh metode deteksi. Hal ini merupakan konsekuensi desain, bukan kesalahan eksperimen. Capping menerapkan batas pagar IQR pada seluruh baris training set tanpa bergantung pada *mask* outlier per-detektor, sedangkan LogTransform diaplikasikan pada seluruh nilai di kolom dengan skewness > 0,5. Dengan demikian, pilihan metode deteksi (IQR, Z-Score, atau Isolation Forest) hanya memberikan dampak yang membedakan pada strategi Removal, ketika *mask* tersebut menentukan baris yang dieliminasi.


Skenario LogTransform menghasilkan AUC-ROC 0,9179, secara praktis setara dengan Baseline (0,9176). Selisih 0,0003 berada dalam rentang variasi sampling pada *single split* dan tidak dapat dipandang sebagai keunggulan tanpa konfirmasi melalui *cross-validation*. F1-Score-nya pun sedikit lebih rendah (0,7851 vs 0,7863). Interpretasi yang lebih konservatif adalah Log Transformation tidak menurunkan performa Baseline, sehingga menjadi alternatif yang aman apabila transformasi tetap diperlukan untuk pertimbangan lain seperti stabilitas numerik.

Sementara itu, metode IQR + Removal menjadi strategi yang paling tidak cocok pada dataset ini karena menghasilkan skor terendah di hampir seluruh metrik, terutama pada Precision (0,4225) dan AUC-ROC (0,6240). Hal ini mengonfirmasi bahwa penghapusan data outlier secara agresif menggunakan IQR justru menghilangkan pola perilaku krusial dalam dataset, sehingga model kehilangan akurasi secara signifikan.


4.4.2.1. Visualisasi Perbandingan Metrik



Gambar 6. Perbandingan Metrik Performa Pada 10 Skenario Eksperimen



Gambar 7. ROC Curve - Perbandingan 10 Skenario Eksperimen



Gambar 8. Confusion Matrix Pada 10 Skenario Eksperimen

4.5. Pembahasan

Berdasarkan visualisasi perbandingan metrik, skenario Baseline (No Treatment) merupakan performa paling unggul dan seimbang dengan F1-Score sebesar 0,7863 dan AUC-ROC 0,918 [6]. Keunggulan ini divalidasi oleh *Confusion Matrix*, di mana Baseline mampu menghasilkan 202 True Positive (deteksi pembeli yang tepat), angka tertinggi dibandingkan seluruh skenario lainnya. Hal ini mengindikasikan bahwa pada dataset *Online Shoppers Intention*, nilai-nilai ekstrem pada fitur bukanlah *noise*, melainkan sinyal krusial yang merepresentasikan perilaku belanja secara nyata.

Penggunaan Log Transformation (IQR, Isolation Forest, dan Z-Score) memberikan hasil yang sangat stabil dan kompetitif. Pada *ROC Curve*, kelompok ini mencapai AUC-ROC tertinggi (0,918), setara dengan Baseline. Meskipun terdapat sedikit penurunan pada F1-Score (0,7851) karena kenaikan tipis pada *False Positive* (61 vs 59 pada Baseline), metode ini tetap mampu mendeteksi 202 pembeli dengan benar. Transformasi logaritma efektif dalam menangani *skewness* tanpa menghilangkan daya prediksi model terhadap kelas minoritas.

Berbeda dengan pembersihan agresif, metode Removal berbasis Isolation Forest dan Z-Score masih menunjukkan performa yang cukup baik dengan F1-Score di kisaran 0,769 dan AUC-ROC 0,916-0,918. *Confusion Matrix* menunjukkan metode ini mampu menangkap 186-187 pembeli. Hal ini menunjukkan bahwa membuang outlier menggunakan algoritma statistik yang cerdas masih jauh lebih baik daripada metode *Capping* atau *Removal* konvensional (IQR) pada dataset ini.

Capping mengalami penurunan performa drastis dengan F1-Score 0,5317 dan AUC-ROC 0,7543. *Confusion Matrix* menunjukkan metode ini hanya berhasil mendeteksi 32 dari 382 pembeli pada test set, sehingga 350 sampel positif gagal teridentifikasi.

Penurunan ini dapat dijelaskan melalui dua efek yang saling memperkuat. Pertama, Capping menumpuk seluruh nilai di atas pagar atas ke satu titik konstan ($Q3 + 1,5 \times IQR$), terlihat sebagai bar tinggi tunggal pada histogram "After Capping" di Gambar 5. Akibatnya, fitur kehilangan daya pembeda antara pengunjung dengan intensitas sedang dan ekstrem karena keduanya bernilai sama. Kedua, sebagaimana diuraikan pada Tabel 6, 90,6% pembeli pada training set memiliki minimal satu fitur yang masuk kategori outlier IQR. Nilai-nilai *PageValues* dan *ProductRelated_Duration* yang menjadi pembeda kelas pembeli dipangkas ke batas yang sama dengan non-pembeli ekstrem, sehingga sinyal diskriminatif tererosi.

Log Transformation tidak mengalami masalah ini karena transformasi $\log(1+x)$ bersifat monoton dan mempertahankan urutan relatif seluruh nilai. Hanya skala yang dikompresi, sedangkan informasi peringkat antar-sampel utuh [5].

Strategi IQR + Removal merupakan skenario terburuk dengan F1-Score terendah (0,4579) dan AUC-ROC terkecil (0,624). Dampak destruktifnya terlihat jelas pada Gambar 8, di mana model menghasilkan 0 True Positive. Artinya, model benar-benar kehilangan kemampuan untuk mendeteksi pembeli sama sekali. Penghapusan baris secara agresif berbasis IQR telah membuang seluruh sampel representatif dari kelas minoritas, sehingga model mengalami bias berat dan hanya mampu memprediksi pengunjung yang tidak belanja.

Kesimpulannya, data asli (Baseline) menjadi pilihan terbaik pada dataset Online Shoppers ini. Jika diperlukan transformasi untuk menormalisasi distribusi, Log Transformation merupakan alternatif paling aman di antara tiga strategi *treatment* yang diuji karena tetap mempertahankan kemampuan deteksi target secara optimal.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berdasarkan serangkaian eksperimen yang telah dilakukan terhadap sepuluh skenario preprocessing outlier pada *Online Shoppers Purchasing Intention Dataset*, dapat ditarik kesimpulan sebagai berikut:

1. Perbandingan efektivitas ketiga metode deteksi outlier menunjukkan perbedaan yang signifikan dalam jumlah sampel yang teridentifikasi. Metode IQR mendeteksi outlier paling banyak, yaitu 5.688 sampel (57,7%), karena bersifat sensitif terhadap distribusi *zero-inflated* dan *right-skewed* yang mendominasi seluruh fitur numerik dataset ini. Metode Z-Score mendeteksi 1.849 sampel (18,7%) dengan toleransi lebih tinggi karena nilai *mean* dan *standard deviation* yang digunakan sebagai acuan turut terdistorsi oleh keberadaan outlier itu sendiri. Isolation Forest mengidentifikasi outlier paling sedikit, yaitu 494 sampel (5,00%), sesuai dengan parameter *contamination* yang ditetapkan, karena pendekatannya yang multivariat lebih konservatif dan hanya menargetkan titik-titik yang terisolasi secara nyata di ruang fitur berdimensi tinggi. Dari sisi strategi treatment, Log Transformation terbukti paling aman diterapkan pada dataset ini karena tidak mengurangi ukuran sampel dan mampu menekan skewness secara efektif. Capping menghasilkan penurunan performa klasifikasi yang drastis, sedangkan Removal berbasis IQR merupakan strategi paling merusak terhadap integritas kelas minoritas pada dataset ini.
2. Kombinasi yang menghasilkan performa klasifikasi terbaik adalah skenario *Baseline* (tanpa treatment apapun) dengan F1-Score 0,7863 dan AUC-ROC 0,9176. Jika transformasi tetap diperlukan, kelompok *LogTransform* (baik dengan IQR, Z-Score, maupun Isolation Forest sebagai detektor) menghasilkan F1-Score 0,7851 dan AUC-ROC tertinggi 0,9179. Hal tersebut merupakan alternatif paling aman di antara tiga strategi *treatment* yang diuji. Strategi Capping dan Removal berbasis IQR menjadi kombinasi terburuk dengan F1-Score masing-masing 0,5317 dan 0,4579.
3. Dampak penerapan setiap strategi preprocessing terhadap stabilitas model sangat bergantung pada karakteristik domain dataset. Pada dataset *e-commerce* yang bersifat perilaku konsumen, nilai ekstrim bukan merupakan *erroneous outlier* melainkan *legitimate extreme* yang merupakan sinyal krusial yang merepresentasikan intensitas belanja nyata. Hal ini dibuktikan oleh fakta bahwa 90,6% dari seluruh pembeli (Revenue=True) dalam dataset teridentifikasi sebagai outlier oleh metode IQR, sehingga Removal berbasis IQR secara efektif menghancurkan kelas minoritas. Dari 1.526 pembeli pada training set, sebanyak 1.383 sampel (90,6%) ikut terhapus oleh strategi IQR+Removal, menyisakan rasio 4.033 non-pembeli berbanding 143 pembeli. Akibatnya, *imbalance ratio* meningkat dari 5,46 menjadi 28,20 dan model kehilangan kemampuan deteksi kelas minoritas, sebagaimana tercermin pada 0 *True Positive* di Confusion Matrix. Baseline unggul bukan karena outlier tidak berpengaruh secara umum, melainkan karena pada konteks ini nilai-nilai ekstrem justru merupakan fitur diskriminatif paling kuat bagi model dalam membedakan pembeli dari non-pembeli.

5.2. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan dalam interpretasi hasil:

1. Evaluasi dilakukan menggunakan *single train-test split* dengan rasio 80:20 dan *random_state* tetap. Pendekatan ini rentan terhadap variabilitas partisi data; penggunaan *k-fold cross-validation* ($k=5$ atau $k=10$) akan menghasilkan estimasi performa yang lebih stabil dan representatif.
2. Hanya satu algoritma klasifikasi, yaitu *Random Forest Classifier*, yang digunakan sebagai evaluator tunggal. Hasil perbandingan antar skenario mungkin berbeda jika diuji menggunakan algoritma lain seperti *Support Vector Machine*, *XGBoost*, atau *Logistic Regression*, yang memiliki sensitivitas berbeda terhadap distribusi fitur.
3. Parameter metode deteksi dan treatment digunakan pada nilai *default* atau nilai yang umum digunakan (IQR $1,5\times$, Z-Score threshold 3, Isolation Forest *contamination* 0,05). *Hyperparameter tuning* pada parameter-parameter ini, seperti menggunakan IQR $3\times$ untuk deteksi outlier ekstrim saja, berpotensi menghasilkan performa yang berbeda.
4. Penelitian ini hanya mengevaluasi tiga strategi treatment secara terpisah. Pendekatan *hybrid*, misalnya menerapkan Log Transformation hanya pada fitur yang memiliki skewness di atas ambang tertentu dan membiarkan fitur lainnya tidak diubah, belum dieksplorasi.
5. Dataset memuat 125 baris duplikat yang tidak dihapus sebelum *train-test split*. Meskipun *stratified sampling* mempertahankan proporsi kelas, terdapat kemungkinan baris identik tersebar di kedua partisi yang secara teknis dapat menjadi bentuk halus dari kebocoran informasi.

5.3. Saran

Untuk pengembangan penelitian selanjutnya, disarankan hal-hal berikut:

1. Mengganti evaluasi *single split* dengan *stratified k-fold cross-validation* ($k=5$ atau $k=10$) agar estimasi F1-Score dan AUC-ROC yang dihasilkan lebih robust dan tidak bergantung pada satu partisi tertentu.
2. Mengeksplorasi pendekatan *selective treatment* dengan strategi *per-feature*. Log Transformation diterapkan hanya pada fitur ber-skewness tinggi dan berskala luas (seperti **_Duration* dan *PageValues*) untuk menstabilkan varians tanpa mengubah urutan relatif, sementara fitur berskala terbatas (*BounceRates* dan *ExitRates* pada rentang $[0; 0,2]$) dibiarkan tanpa transformasi karena manfaat log pada skala tersebut tidak signifikan.
3. Menambahkan analisis *feature importance* sebelum dan sesudah treatment untuk mengukur secara kuantitatif seberapa besar penurunan kontribusi fitur kunci akibat setiap strategi preprocessing yang diterapkan.
4. Mengulang eksperimen setelah menerapkan *drop_duplicates()* sebelum split guna mengonfirmasi sejauh mana ranking sepuluh skenario terpengaruh oleh keberadaan duplikat.

DAFTAR PUSTAKA

- [1] M. Alenezi et al., "Enhancing classification performance in imbalanced datasets: A comparative analysis of machine learning models," *AIMS Mathematics*, vol. 8, no. 12, 2023.
- [2] P. M. Mah, I. Skalna, and T. Pelech-Pilichowski, "AI-Driven Anomaly Detection in E-Commerce Services: A Deep Learning and NLP Approach to the Isolation Forest Algorithm Trees," *Journal of Theoretical and Applied Electronic Commerce Research*, vol. 20, no. 3, 2025.
- [3] P. Koukaras and C. Tjortjis, "Data Preprocessing and Feature Engineering for Data Mining: Techniques, Tools, and Best Practices," *AI*, vol. 6, no. 10, p. 257, 2025.
- [4] D. Samariya and A. Thakkar, "A Comprehensive Survey of Anomaly Detection Algorithms," *Annals of Data Science*, vol. 10, pp. 829-850, 2023. DOI: 10.1007/s40745-021-00362-9.
- [5] M. M. Ahsan, M. A. P. Mahmud, P. K. Saha, K. D. Gupta, dan Z. Siddique, "Effect of data scaling methods on machine learning algorithms and model performance," *Technologies*, vol. 9, no. 3, art. 52, 2021. doi: 10.3390/technologies9030052.
- [6] L. Dube dan T. Verster, "Interpretability of the random forest model under class imbalance," *Data Science in Finance and Economics*, vol. 4, no. 3, pp. 446–468, 2024. doi: 10.3934/DSFE.2024019.

LAMPIRAN

Tabel Kontribusi Anggota Tim

No	Nama	Tugas dan Tanggung Jawab
1	Muhammad Nurikhsan	Koordinasi tim, penyusunan kerangka laporan (BAB I & II), implementasi pipeline eksperimen Python (train-test split, deteksi outlier, training model)
2	Aryasatya Widyatna Akbar	Implementasi metode deteksi outlier (IQR, Z-Score, Isolation Forest), penyusunan Tabel 5 ringkasan hasil deteksi, analisis perbandingan jumlah outlier per metode
3	Giovan Lado	Implementasi strategi treatment outlier (Removal, Capping, Log Transformation), penyusunan visualisasi Before vs After distribusi fitur (Gambar 5)
4	Louis Hutabarat	Penyusunan BAB III Metodologi Penelitian, penyusunan alur penelitian (Gambar 1), validasi prosedur train-test split dan pencegahan data leakage
5	Muhammad Fajri Firdaus	Penyusunan BAB IV Hasil dan Pembahasan, interpretasi confusion matrix (Gambar 8), analisis perbandingan metrik antar skenario (Tabel 8)
6	Martino Kelvin	Penyusunan visualisasi metrik performa (Gambar 6 & 7 ROC Curve), penyusunan daftar pustaka, formatting dan finalisasi dokumen laporan