

LOGBOOK PROJECT KELOMPOK

Mata Kuliah Penambangan Data

Informasi Project

Judul Project	Analisis Komparatif Metode Deteksi dan Strategi Penanganan Outlier terhadap Performa Model Klasifikasi pada Online Shoppers Purchasing Intention Dataset
Tools	Python, Google Colab, Pandas, numpy, scipy.stats, sklearn.ensemble, sklearn.preprocessing, sklearn.model_selection, sklearn.metrics, Matplotlib
Jenis Project	Program Python berbasis Google Colab

Anggota Kelompok

No	NIM	Nama	Tugas
1	123140057	Muhammad Nurikhsan	Koordinasi tim, penyusunan kerangka laporan (BAB I & II), implementasi pipeline eksperimen Python (train-test split, deteksi outlier, training model)
2	123140164	Aryasatya Widyatna Akbar	Implementasi metode deteksi outlier (IQR, Z-Score, Isolation Forest), penyusunan Tabel 5 ringkasan hasil deteksi, analisis perbandingan jumlah outlier per metode
3	123140068	Giovan Lado	Implementasi strategi treatment outlier (Removal, Capping, Log Transformation), penyusunan visualisasi Before vs After distribusi fitur (Gambar 5)
4	123140052	Louis Hutabarat	Penyusunan BAB III Metodologi Penelitian, penyusunan alur penelitian (Gambar 1), validasi prosedur train-test split dan pencegahan data leakage
5	123140050	Muhammad Fajri Firdaus	Penyusunan BAB IV Hasil dan Pembahasan, interpretasi confusion matrix (Gambar 8), analisis perbandingan metrik antar skenario (Tabel 8)
6	123140165	Martino Kelvin	Penyusunan visualisasi metrik performa (Gambar 6 & 7 ROC Curve), penyusunan daftar pustaka, formatting dan finalisasi dokumen laporan

Logbook 10 Pertemuan (Mulai Minggu ke-7)

Minggu	Kegiatan	Output	Penanggung Jawab
7	Kick-off project dan pembentukan kelompok. Diskusi	Struktur tim terbentuk, topik dan dataset	Seluruh anggota

	topik penelitian, pemilihan dataset Online Shoppers Purchasing Intention dari UCI ML Repository. Pembagian peran dan tanggung jawab antar anggota tim.	disepakati, pembagian tugas awal setiap anggota.	
8	Studi literatur terkait konsep outlier, metode deteksi (IQR, Z-Score, Isolation Forest), strategi penanganan outlier (Removal, Capping, Log Transformation), dan metrik evaluasi klasifikasi. Penyusunan kerangka laporan BAB I (Pendahuluan) dan BAB II (Tinjauan Pustaka).	Draft BAB I (Latar Belakang, Rumusan Masalah, Tujuan, Batasan Masalah) dan BAB II (Tinjauan Pustaka) selesai. Tabel 1 perbandingan metode deteksi dan Tabel 2 strategi treatment tersusun.	Muhammad Nurikhsan
9	Draft BAB I (Latar Belakang, Rumusan Masalah, Tujuan, Batasan Masalah) dan BAB II (Tinjauan Pustaka) selesai. Tabel 1 perbandingan metode deteksi dan Tabel 2 strategi treatment tersusun.	Draft BAB III Metodologi Penelitian selesai. Alur penelitian (Gambar 1) terbentuk. Prosedur train-test split 80:20 dengan stratified sampling dikonfirmasi.	Louis Hutabarat
10	Setup lingkungan kerja di Google Colab. Pemuatan dan eksplorasi awal dataset (12.330 sampel, 18 kolom). Analisis statistik deskriptif fitur numerik, pengecekan missing values dan duplikat. Visualisasi distribusi fitur numerik (Gambar 2) dan distribusi kelas target Revenue (Gambar 3). Pembuatan boxplot outlier visual (Gambar 4).	Tabel 4 Statistik Deskriptif Fitur Numerik tersusun. Gambar 2 (distribusi fitur), Gambar 3 (distribusi kelas), dan Gambar 4 (boxplot) dihasilkan. Temuan: 0% missing values, 125 duplikat, seluruh fitur numerik right-skewed (skewness > 1).	Louis Hutabarat
11	Implementasi pipeline train-test split (stratified, 80:20) menghasilkan training set 9.864 sampel dan test set 2.466 sampel. Implementasi tiga metode deteksi outlier pada training set: IQR ($1,5 \times \text{IQR}$), Z-Score ($ z > 3$), dan Isolation Forest (contamination=0,05). Analisis perbandingan jumlah outlier yang terdeteksi setiap metode. Penyusunan Tabel 5 ringkasan hasil deteksi dan Tabel 6 rata-rata fitur per kelas target.	Tabel 5: IQR mendeteksi 5.688 outlier (57,7%), Z-Score 1.849 (18,7%), Isolation Forest 494 (5,0%). Tabel 6 menunjukkan pembeli memiliki nilai fitur durasi dan PageValues jauh lebih tinggi. Tabel 7 mask IQR: 90,6% pembeli teridentifikasi sebagai outlier IQR.	Aryasatya Widyatna Akbar
12	Implementasi tiga strategi treatment outlier pada training set: (1) Removal – menghapus baris outlier, (2) Capping/Winsorization – membatasi nilai ke batas IQR tanpa mengurangi sampel, (3) Log Transformation $\log(1+x)$ – diterapkan pada fitur dengan skewness > 0,5. Pembuatan	Gambar 5 visualisasi distribusi Before vs After seluruh treatment selesai. Temuan: Log Transformation paling efektif menekan skewness tanpa menghilangkan data. Removal berbasis IQR menghapus 90,6% pembeli dari training set.	Giovan Lado

	visualisasi Before vs After distribusi untuk fitur ProductRelated_Duration, Administrative_Duration, Informational_Duration, PageValues, dan ExitRates (Gambar 5).		
13	Implementasi pipeline evaluasi lengkap untuk 10 skenario eksperimen (9 kombinasi deteksi $\times$ treatment + 1 baseline). Training Random Forest Classifier (n_estimators=100, class_weight='balanced', random_state=42) pada setiap skenario. Evaluasi performa menggunakan test set asli (tanpa modifikasi). Pengumpulan metrik: Accuracy, Precision, Recall, F1-Score, AUC-ROC.	Tabel 9 Pipeline Evaluasi 10 Skenario Eksperimen selesai. Hasil terbaik: Baseline (F1=0,7863, AUC=0,9176). Hasil terburuk: IQR+Removal (F1=0,4579, AUC=0,6240). LogTransform setara Baseline (AUC=0,9179).	Muhammad Fajri Firdaus
14	Pembuatan visualisasi perbandingan metrik (Gambar 6 bar chart 10 skenario), ROC Curve semua skenario (Gambar 7), dan Confusion Matrix 10 skenario (Gambar 8). Penulisan BAB IV Hasil dan Pembahasan secara lengkap, termasuk analisis mengapa Capping merusak sinyal kelas minoritas dan mengapa IQR+Removal menyebabkan 0 True Positive.	Gambar 6, 7, dan 8 dihasilkan. Draft BAB IV Hasil dan Pembahasan selesai. Penyusunan BAB V Kesimpulan dan Saran, serta identifikasi keterbatasan penelitian (single split, satu algoritma, parameter default).	Muhammad Fajri Firdaus
15	Finalisasi dan integrasi seluruh bagian laporan (BAB I–V, Daftar Pustaka, Lampiran Tabel Kontribusi). Review dan penyempurnaan formatting dokumen. Penyusunan daftar pustaka (6 referensi jurnal ilmiah). Pembuatan poster project, video demonstrasi, dan pengumpulan repository GitHub. Pengumpulan laporan final.	Laporan ilmiah lengkap (BAB I–V + Lampiran) siap dikumpulkan. Poster project, video demonstrasi, dan repository GitHub tersedia. Seluruh output project selesai dan terdokumentasi.	Martino Kelvin

Output Project

- Program Python berbasis Google Colab
- Visualisasi grafik hasil analisis data
- Repository GitHub

Seluruh implementasi project dilakukan menggunakan Python pada Google Colab tanpa pengembangan UI/UX maupun frontend/backend.

